

STANDORTPOTENZIALE ERKENNEN: BUSINESS ANALYTICS FÜR WERTSTEIGERENDE IMMOBILIENINVESTITIONEN IM KANTON ZÜRICH

CASE STUDY BINA FS25 – GRUPPE 10



ZIELE

Analyse relevanter
Indikatoren und deren
Relevanz für die
Preisbestimmung

Identifikation von
attraktiven
Investitionsstandorten im
Kanton Zürich

Ableitung für
Handlungsempfehlungen
für eine
Immobilieninvestitionsfirma

DATENGRUNDLAGE

Folgende Datentabellen dienen als Grundlage für die Arbeit:

Bevölkerungswachstum:
Entwicklung der
Einwohnerzahlen als
Indikator für Nachfrage.

Kriminalitätsrate:
Sicherheit als Faktor für
Lebensqualität.

Arbeitslosenquote:
Wirtschaftliche Stabilität
der Gemeinde.

Fahrtzeit nach Zürich:
Erreichbarkeit des
Wirtschafts- und
Arbeitszentrums Zürich.

Steuerfuss: Steuerliche
Attraktivität für
Privatpersonen und
Unternehmen.



Datentabellen verstehen

DATENBEREINIGUNG

- Generell:
 - Nicht benötigte Spalten löschen
 - Spaltentitel umbenennen auf einheitliche Spaltentitel
 - Leere Felder bereinigen
- Kriminalitätsrate:
 - Gruppieren und Summieren nach Jahr und Bezirk

```
url = 'https://raw.githubusercontent.com/Bina-G10/BINA-G10/refs/heads/main/Daten/Anzahl%20Straftaten%20nach%20Tatbestand%20und%20Bezirken.csv'
straftaten = pd.read_csv(url)

#Spalten löschen
straftaten = straftaten.drop(['Gesetz_Nummer', 'Gesetz_Abk', 'Reihenfolge_Haupttitel', "Haupttitel", "Artikel", "Tatbestand"], axis=1)
#Häufigkeitszahl ist Dunkelziffer

#Gruppieren und Summieren nach Jahr und Bezirk
agg_cols = (["Straftaten_total", "Straftaten_vollendet", "Straftaten_versucht", "Häufigkeitszahl"])
straftaten_summiert = straftaten.groupby(["Ausgangsjahr", "Bezirk_BFS_Nr", "Bezirksname"], as_index=False)[agg_cols].sum()

#Dokumentieren weshalb alle Tatbestände gesammelt betrachtet werden

# Optional: Die ersten Zeilen anzeigen
print(straftaten_summiert.head())
```

DATENTABELLEN MERGEN

01

Alle Datentabellen auf Gemeindeebene mergen:

- Bevölkerungswachstum: Entwicklung der Einwohnerzahlen als Indikator für Nachfrage.
- Arbeitslosenquote: Wirtschaftliche Stabilität der Gemeinde.
- Fahrtzeit nach Zürich: Erreichbarkeit des Wirtschafts- und Arbeitszentrums Zürich.
- Steuerfuss: Steuerliche Attraktivität für Privatpersonen und Unternehmen.

02

Bezirkscode aus Bezirks-Gemeinde-Tabelle ergänzen

03

Datentabelle auf Bezirksebene mergen:

- Kriminalitätsrate: Sicherheit als Faktor für Lebensqualität.

04

Auf gemeinsamen Zeitraum mergen

- 2012 bis 2023

REGRESSION

Target y :

- Baulandpreis Median (Medianpreis für unbebautes Wohnland in Fr./m²).

Features X :

- Arbeitslosenanteil (%)
- Bevölkerungsdichte (Einwohner/km²)
- Steuerfuss ohne Kirche (Steuersatz)
- Juristische Personen (Steuersatz)
- Straftaten_total (Anzahl)
- Häufigkeitszahl (Kriminalitätsrate)
- Fahrzeit nach Zürich (Minuten)

MODELLTRAINING UND -EVALUATION

Train/Test-Split: 80 % der Daten zum Trainieren, 20 % zum Testen.



Lineare Regression mit Imputation & Standardisierung als Baseline:

$$R^2 = 0.754$$

$$\text{RMSE} \approx 303 \text{ Fr./m}^2$$

Wenig aussagekräftig,
wird nicht weiterverfolgt



Random Forest Regressor mit Imputation:

$$R^2 = 0.856$$

$$\text{RMSE} \approx 232 \text{ Fr./m}^2$$

Aussagekräftig, wird
weiterverwendet

RANDOM FOREST REGRESSOR – HYPERPARAMETER-TUNING 1/2

Ziel

- Optimale Einstellungen für das Random Forest Modell finden, um Prognosegüte zu maximieren (RMSE minimieren, R^2 steigern)

Vorgehen


- Parameter-Raster (Grid) mit verschiedenen Werten für zentrale Hyperparameter definiert:
 - `n_estimators` (Anzahl Bäume)
 - `max_depth` (maximale Baumtiefe)
 - `max_features` (Anzahl Merkmale pro Split)
 - `min_samples_split` (minimale Samples pro Split)
 - `min_samples_leaf` (minimale Samples pro Blatt)
- Pipeline: Imputation (SimpleImputer, Median) + Random Forest
- Optimierung mit GridSearchCV und TimeSeriesSplit (zeitbasierte Kreuzvalidierung) – verhindert Datenlecks und prüft Generalisierbarkeit

RANDOM FOREST REGRESSOR – HYPERPARAMETER-TUNING 2/2

Ergebnis

- Beste Parameter:
 - `n_estimators = 200`
 - `max_depth = 20`
 - `max_features = 'sqrt'`
 - `min_samples_split = 2`
 - `min_samples_leaf = 1`
- Finales Modell auf Gesamtdaten trainiert und die Performance deutlich verbessert
 - Vorhersagefehler reduziert und erklärte Varianz gesteigert
- Test-Set:
 - $R^2 = 0.926$
 - $RMSE \approx 166 \text{ Fr./m}^2$
- Cross-Validation:
 - Durchschnittlicher CV-RMSE $\approx 266 \text{ Fr./m}^2$


ANWENDUNG DES ERSTELLTEN RANDOM FOREST MODELLS 1/2



1. Fahrzeit nach Zürich: stärkster Prädiktor
kurze Fahrzeit = hohe Preise
2. Steuerdruck (Steuerfuss + juristische Personen):
hoher Steuerdruck = hohe Preise
3. Bevölkerungsdichte:
dichter besiedelte Gemeinden = teurere Grundstücke
4. Kriminalitätsindex & Arbeitslosenanteil:
nur geringer Einfluss

Fazit: Erreichbarkeit und steuerliche Rahmenbedingungen bestimmen Preisentwicklung am stärksten


ANWENDUNG DES ERSTELLTEN RANDOM FOREST MODELLS 2/2



Einfluss der wichtigsten Indikatoren auf den Preis

- Fahrzeit nach Zürich:
Je kürzer die Fahrzeit, desto höher der Preis
- Bevölkerungsdichte:
Je höher die Dichte, desto höher der Preis
- Steuerdruck:
Je tiefer der Steuerdruck, desto höher der Preis

BEWERTUNG DER MODELLGÜTE



- Modell trifft die Mehrheit der Vorhersagen präzise
- Punkte liegen eng an Ideallinie
- Widerspielt sich im tiefen RMSE

GRENZEN DES RANDOM FOREST MODELLS

- Es sind keine Vorhersagen mit dem Modell möglich
- Keine Veränderung der Input-Variablen → Modell prognostiziert für 2030 die gleichen Preise wie für 2025 („Null-Delta“)
- Tatsächliche Preisentwicklung 2012–2023: Deutlicher Anstieg, der im Modell nur abgebildet wird, wenn sich auch die Indikatoren ändern
- Für realistische 2030-Prognosen müssen plausible Szenarien für alle Einflussfaktoren erstellt werden (z. B. Bevölkerungsentwicklung, Steuertrends, Kriminalitätsrate, Erreichbarkeit)
- Ohne Annahmen zu zukünftigen Entwicklungen bleibt die Prognose eine Fortschreibung des Status quo und ist nicht belastbar

XGBOOST-REGRESSOR MODELL

Hypothesen

- Verbesserte Prognosegüte: XGBoost kann RMSE weiter senken und die Vorhersagekraft gegenüber Random Forest steigern
- Robustheit gegenüber Ausreißern: Modell liefert stabilere Preisprognosen, auch bei Extremwerten
- Präzisere Erfassung von Feature-Interaktionen: Wechselwirkungen zwischen Einflussgrößen werden effektiver erkannt und gewichtet


Validierung

- TimeSeries-Cross-Validation zur Sicherstellung der zeitlichen Generalisierbarkeit (insbesondere für Prognosen bis 2030)
- SHAP-Analysen zum Vergleich der wichtigsten Einflussfaktoren mit dem Random Forest-Modell

Ziel

- Prognosequalität und Interpretierbarkeit weiter verbessern
- Stärken moderner Boosting-Algorithmen optimal für die Immobilienbewertung im Kanton Zürich nutzen


ANWENDUNG DES XGBOOST-REGRESSOR MODELLS



1. Steuerdruck (Steuerfuss + juristische Personen):
hoher Steuerdruck = hohe Preise
2. Fahrzeit nach Zürich:
kurze Fahrzeit = hohe Preise
3. Bevölkerungsdichte:
dichter besiedelte Gemeinden = teurere Grundstücke
4. Kriminalitätsindex & Arbeitslosenanteil:
nur geringer Einfluss

Fazit: Steuerliche Rahmenbedingungen bestimmen Preisentwicklung am stärksten

BEWERTUNG DER MODELLGÜTE



- XGBoost liefert sehr präzise Vorhersagen auf Testdaten
- Zeitliche Übertragbarkeit ist noch nicht durchgehend stabil
- Modell besonders geeignet für aktuelle Prognosen, mit Potenzial zur weiteren Optimierung für Langfristprognosen

VERGLEICH DER BEIDEN REGRESSIONSMODELLE

Random Forest

- R^2 : 0,86–0,92
- RMSE: 170–230 Fr./m²
- CV- R^2 (TimeSeriesSplit): stabil zwischen 0,45–0,55
- Sehr robust, geringe Varianz durch Bagging-Verfahren

XGBoost

- R^2 : 0,932 (Test-Set)
- RMSE: 159,4 Fr./m² (Test-Set)
- CV- R^2 : 0,386–0,484 (höhere Schwankungen, sensibler gegenüber Zeitabschnitten)
- Geringerer Bias, höhere Genauigkeit durch sequentielles Boosting

PROGNOSE FÜR JAHR 2030 - VORGEHEN


Methode

- Lineare Extrapolation:
Durchschnittliche jährliche Wachstums-/Rückgangsrage seit 2010 berechnen und bis 2030 fortschreiben
- Time-Series-Forecast:
Zeitreihenmodelle (z. B. ARIMA, Prophet) für nicht-lineare oder saisonale Merkmale einsetzen
- Konstante Annahme:
Unveränderte Werte für stabile Merkmale (z. B. Fahrzeit)


Umsetzung

- Aufbau eines DataFrames für 2030 mit extrapolierten/forecasteten Indikatoren
- Anwendung des trainierten XGBoost-Modells auf diese Szenarien


ERGEBNISSE DER PROGNOSE MIT DEM XGBOOST-MODELL 1/4




ERGEBNISSE DER PROGNOSE MIT DEM XGBOOST-MODELL 2/4



ERGEBNISSE DER PROGNOSE MIT DEM XGBOOST-MODELL 3/4



ERGEBNISSE DER PROGNOSE MIT DEM XGBOOST-MODELL 4/4



HANDLUNGSEMPFEHLUNGEN 1/2

Empfohlene Investitionsstandorte

- Zell:
Stärkster prognostizierter prozentualer Preisanstieg (73.1%)
Bei einem Ausgangspreis (2023) von 487 Fr. /m²
- Opfikon:
Stärkster prognostizierter absoluter Preisanstieg
(2'737 → 4'675 Fr./m²)
Dynamisches Bevölkerungswachstum & attraktive steuerliche
Rahmenbedingungen
- Lufingen :
Deutlicher Wertzuwachs (902 → 1'437 Fr./m²)
Positiver Trend bei Standortfaktoren
- Oberglatt:
Starkes Wachstum von niedrigem Ausgangsniveau
(970 → 1'510 Fr./m²)

HANDLUNGSEMPFEHLUNGEN 2/2

01

Fokus auf Gemeinden mit niedrigem aktuellem Preisniveau und hohem prognostizierten Wachstum wie in Zell

02

Grösstes Wertsteigerungspotenzial und überdurchschnittliche Rendite in Lufingen und Oberglatt

03

Besonders dynamisch wachsende Gemeinden wie Opfikon und Fällanden bieten hohe Renditechancen

FAZIT

Datenbasierte Methoden und Machine Learning liefern fundierte Entscheidungsgrundlagen für Immobilieninvestitionen im Kanton Zürich

Entwicklung eines robusten Modells, das die Komplexität und Heterogenität des Marktes abbildet

Einsatz von Random Forest und XGBoost

- Präzise Quantifizierung der Zusammenhänge zwischen Standortfaktoren und Baulandpreisen
- Fahrzeit nach Zürich, Steuerdruck und Bevölkerungsdichte als wichtigste Preistreiber identifiziert

Prognosen bis 2030 zeigen:

- Starke Wertsteigerungen in dynamisch wachsenden Gemeinden (z.B. Opfikon, Oberglatt)
- Hochpreisige Standorte (z.B. Zürich, Kilchberg, Zollikon) mit begrenztem Wachstumspotenzial oder Rückgängen

Empfehlung: Fokus auf Gemeinden mit günstigen Ausgangsniveaus und positiven Trends für maximales Wertsteigerungspotenzial